

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Analiza recenzji hotelowych przy użyciu technik text mining

Wersja dokumentu: 1.0

Data: 31.05.2026

Autorzy: Sonia Niewiadomska, Jan Osik

Spis treści

1. Wprowadzenie.....	1
2. Cele systemu.....	1
3. Wymagania funkcjonalne.....	2
4. Wymagania нефункционалне.....	3
5. Interfejsy użytkownika.....	3
6. Wymagania dotyczące danych.....	4
7. Przypadki użycia (use cases).....	5
8. Scenariusze użytkownika (user stories).....	6
9. Podział pracy członków zespołu.....	7

1. Wprowadzenie

Dokument opisuje specyfikację wymagań dla systemu analizy opinii hotelowych pochodzących z serwisu TripAdvisor. System będzie wykorzystywał techniki eksploracji tekstu (text mining) do przetwarzania i analizy recenzji użytkowników. Projekt zostanie zrealizowany w środowisku R z wykorzystaniem bibliotek do analizy tekstu i uczenia maszynowego.

2. Cele systemu

- Automatyczna analiza dużej liczby opinii hotelowych.
- Identyfikacja najważniejszych słów i fraz występujących w recenzjach.
- Ocena wydźwięku emocjonalnego opinii (pozytywny, neutralny, negatywny).
- Budowa modelu klasyfikacji opinii na podstawie ich treści.
- Wizualizacja wyników analizy.

- Wspomaganie procesu oceny jakości usług hotelowych.

3. Wymagania funkcjonalne

- Wczytywanie danych
 - system powinien umożliwiać import danych z pliku CSV zawierającego opinie hotelowe
- Przygotowanie danych
 - usuwanie znaków specjalnych,
 - usuwanie liczb,
 - usuwanie słów nieistotnych (stop words),
 - zamienianie tekstów na małe litery,
 - wykonywanie stemmingu
- Analiza TF-IDF
 - obliczanie wartości TF-IDF dla wszystkich słów,
 - identyfikowanie słów najbardziej charakterystycznych dla opinii
- Klasyfikacja
 - dzielenie danych na zbiór treningowy i testowy,
 - trenowanie modelu klasyfikacyjnego,
 - przewidywanie klasy opinii na podstawie treści tekstu
- Ocena modelu

Wyznaczanie:

- accuracy,
 - precision,
 - recall,
 - F1-score,
 - macierz pomyłek.
- Wizualizacja wyników
 - wykres najczęściej występujących słów (chmura słów),
 - wykres wartości TF-IDF,
 - wizualizacja wyników klasyfikacji

4. Wymagania niefunkcjonalne

- Wydajność
 - System powinien analizować zbiór zawierający minimum 5 000 opinii w czasie nieprzekraczającym kilku minut na standardowym komputerze.
- Bezpieczeństwo
 - System powinien zapewnić poprawność danych wyjściowych.
- Niezawodność
 - System powinien poprawnie obsługiwać brakujące wartości, niekompletne dane oraz różne formaty danych.
- Użyteczność
 - Wyniki powinny być prezentowane w czytelnej formie tabel i wykresów.
- Przenośność
 - System powinien działać na systemach Windows, Linux oraz macOS posiadających środowisko R.
- Rozszerzalność
 - Możliwe powinno być dodanie kolejnych metod klasyfikacji.

5. Interfejsy użytkownika

Projekt będzie realizowany jako skrypt lub notebook w środowisku RStudio.

Użytkownik będzie mógł wskazać plik z danymi, uruchomić analizę oraz przeglądać wyniki i wykresy.

- Wejście
 - Plik CSV zawierający treść opinii oraz ocenę użytkownika.
- Wyjście
 - listę słów z najwyższym TF-IDF,
 - klasy przewidziane przez model,
 - miary jakości klasyfikacji,
 - wykresy i raport końcowy.

6. Wymagania dotyczące danych

- Każdy rekord powinien zawierać co najmniej: treść opinii (tekst recenzji), ocenę użytkownika w skali od 1 do 5.
- Dane powinny być zapisane w formacie CSV.
- Dane powinny zawierać poprawnie zakodowany tekst (UTF-8).
- Dane powinny posiadać niepuste pola z treścią opinii.
- Dane powinny zawierać przypisaną ocenę dla każdej opinii.
- Skrypt zakłada, że dane są w języku angielskim.
- Zalecana liczba opinii: około 20 000 rekordów (dane treningowe ok. 15 000 , dane testowe ok. 4 000).

Słownictwo dokumentacji

- Text Mining: analiza danych tekstowych
- TF-IDF: miara określająca ważność słowa w dokumencie
- Klasyfikacja: przypisanie obiektu do określonej klasy
- Accuracy: procent poprawnych predykcji
- Precision: dokładność klasyfikacji pozytywnej
- Recall: czułość modelu
- F1-score: średnia harmoniczna precision i recall
- Stop words: powszechne słowa usuwane podczas analizy tekstu

7. Przypadki użycia (use cases)

- Użytkownik
 - wczytuje plik,
 - uruchamia analizę,
 - wyświetla wyniki
- System
 - przetwarza tekst,
 - generuje wykresy,
 - generuje chmurę słów,
 - określa miary TF-IDF słów,
 - dzieli na klasy,
 - podaje miary jakości klasyfikacji
- Testowe przypadki użycia
 - Test z plikiem klasyfikowanym pozytywnie,
 - Test z plikiem klasyfikowanym negatywnie,
 - Test z plikiem klasyfikowanym neutralnie,
 - Test z plikiem zawierającym brakujące wartości,
 - Testy o różnych miarach TF-IDF

8. Scenariusze użytkownika (user stories)

Scenariusz 1: Analiza TF-IDF opinii hotelowych

- Jako: Analityk danych, Menedżer hotelu
- Chcę: Obliczyć wartości TF-IDF dla słów występujących w opiniach hotelowych
- Aby: Zidentyfikować słowa najbardziej charakterystyczne dla poszczególnych opinii oraz całego zbioru danych, poznać opinie klientów i wykrywać problemy

Kryteria akceptacji:

- system poprawnie wczytuje zbiór opinii hotelowych,
- tekst zostaje poddany preprocessingowi (usunięcie stop words, znaków specjalnych i zamiana na małe litery),
- dla każdego słowa zostaje obliczona wartość TF-IDF,
- system generuje ranking słów o najwyższych wartościach TF-IDF,
- użytkownik może wyświetlić wyniki w formie tabeli lub wykresu,
- obliczenia są wykonywane dla całego zbioru danych bez błędów.

Scenariusz 2: Klasyfikacja opinii hotelowych

- Jako: Analityk danych, Specjalista ds. jakości usług
- Chcę: Zbudować model klasyfikacyjny, który przewiduje ocenę opinii na podstawie jej treści
- Aby: Automatycznie określać, czy nowa opinia jest pozytywna, negatywna lub neutralna, identyfikować obszary wymagające poprawy

Kryteria akceptacji:

- dane są poprawnie podzielone na zbiór treningowy i testowy,
- tekst opinii jest reprezentowany przy użyciu TF-IDF,
- model klasyfikacyjny (np. Naive Bayes lub Random Forest) jest poprawnie wytrenowany,
- system potrafi przewidzieć klasę nowej opinii,
- wyniki modelu są oceniane za pomocą metryk: accuracy, precision, recall i F1-score,
- macierz pomyłek jest generowana i możliwa do interpretacji.

Scenariusz 3: Ocena skuteczności modelu klasyfikacyjnego

- Jako: Administrator systemu
- Chcę: Ocenic skuteczność wytrenowanego modelu klasyfikacyjnego
- Aby: Sprawdzic, czy model poprawnie przewiduje klasy opinii hotelowych

Kryteria akceptacji:

- system przeprowadza predykcje na zbiorze testowym,
- generowana jest macierz pomyłek,
- obliczane sa miary accuracy, precision, recall oraz F1-score,
- wyniki sa prezentowane uzytkownikowi w czytelnej formie,
- uzytkownik moze porownac skuteczność różnych modeli klasyfikacyjnych.

9. Podział pracy członków zespołu

Sonia Niewiadomska: dobór danych, dokumentacja SRS, weryfikacja kodu

Jan Osik: dobór danych, realizacja skryptu oraz raportu HTML, weryfikacja dokumentacji